القسم الأول: اختيار من متعدد (٢٠ سؤال)

الهدف الأساسي من NLP هو:

أ) تحليل الصور

ب) فهم اللغة البشرية

ج) تحسين الشبكات

د) ضغط البيانات

Tokenization تعني:

أ) ترجمة النص

ب) تقسيم النص

ج) ضغط النص

د) حذف الكلمات

Stop Words هي:

أ) كلمات نادرة

ب) كلمات شائعة قليلة القيمة

ج) كلمات تقنية

د) كلمات طويلة

TF-IDF يستخدم لـ:

أ) الترجمة

ب) تمثيل النص

ج) تصنيف الصور

د) ضغط البيانات

Bag of Words:

أ) يحافظ على ترتيب الكلمات

ب) يهمل الترتيب

ج) يستخدم الشبكات العصبية

د) يعتمد على السياق

أي نموذج يعتمد على السياق؟

أ) TF-IDF

ب) Bag of Words

ج) BERT

د) Count Vector

Lemmatization:

أ) تقطيع النص

ب) تحويل الكلمة لأصلها

ج) حذف الكلمات

د) ضغط النص

Word2Vec ينتج:

أ) صور

ب) متجهات

ج) جمل

د) قواعد

أي خوارزمية مناسبة لتصنيف النص؟

أ) KNN

ب) Naive Bayes

ج) Decision Tree

د) جميع ما سبق

NER تعني:

أ) تحليل المشاعر

ب) التعرف على الكيانات

ج) الترجمة

د) تصنيف النص

Overfitting يعني:

أ) نموذج ضعيف

ب) نموذج يحفظ البيانات

ج) نموذج سريع

د) نموذج بسيط

Underfitting يعني:

أ) نموذج بسيط جدًا

ب) نموذج معقد

ج) نموذج دقيق

د) نموذج سريع

Embedding هو:

أ) صورة

ب) تمثيل رقمي للكلمات

ج) نص

د) خوارزمية

Language Model هدفه:

أ) الترجمة

ب) توقع الكلمة التالية

ج) ضغط النص

د) حذف الكلمات

Transformer يعتمد على:

أ) CNN

ب) RNN

ج) Attention

د) KNN

Attention يساعد في:

أ) حذف الكلمات

ب) التركيز على الكلمات المهمة

ج) ضغط النص

د) تحويل النص

POS Tagging:

أ) ترجمة

ب) تحديد نوع الكلمة

ج) حذف الكلمات

د) تحليل الصور

أي مما يلي Unsupervised؟

أ) Classification

ب) Clustering

ج) Regression

د) Decision Tree

Cosine Similarity تستخدم لـ:

أ) الترجمة

ب) قياس التشابه

ج) تصنيف الصور

د) ضغط النص

GPT هو:

أ) نموذج لغة

ب) خوارزمية تصنيف

ج) قاعدة بيانات

د) نظام تشغيل

✍القسم الثاني: أسئلة نظرية (١٥ سؤال)

اشرح مفهوم Tokenization مع مثال.

Tokenization هي عملية تقسيم النص إلى وحدات صغيرة تسمى Tokens، وقد تكون كلمات أو جمل أو حتى أجزاء من كلمات.

مثال:

النص:

"الذكاء الاصطناعي يغير العالم"

بعد Tokenization:

["الذكاء"، "الاصطناعي"، "يغير"، "العالم"]

ما الفرق بين Stemming و Lemmatization؟

Stemming

تقصير الكلمة إلى جذر تقريبي

قد ينتج كلمة غير صحيحة لغويًا

مثال:

playing → play

studies → studi

Lemmatization

إرجاع الكلمة إلى شكلها القاموسي الصحيح

يعتمد على القواعد اللغوية

مثال:

better → good

running → run

الفرق الأساسي:

Stemming أسرع لكنه أقل دقة

Lemmatization أبطأ لكنه أدق

ما هو Bag of Words؟ وما عيوبه؟

Bag of Words (BoW) هو طريقة لتحويل النص إلى أرقام عن طريق عدّ تكرار الكلمات داخل النص.

مثال:

الجملتان:

"أنا أحب الذكاء"

"الذكاء مهم"

القاموس: ["أنا"، "أحب"، "الذكاء"، "مهم"]

تمثيل الجملة الأولى: [١، ١، ١، ٠]

العيوب:

يهمل ترتيب الكلمات

لا يفهم المعنى أو السياق

ينتج متجهات كبيرة sparse

لا يعرف أن:

"جميل" و"رائع" قريبان في المعنى

اشرح TF-IDF وكيف يعمل.

TF-IDF = Term Frequency - Inverse Document Frequency

يستخدم لقياس أهمية الكلمة داخل مستند مقارنة بباقي المستندات.

يتكون من:

TF (Term Frequency)

عدد مرات ظهور الكلمة في المستند.

IDF (Inverse Document Frequency)

يقيس ندرة الكلمة في جميع المستندات.

الفكرة:

الكلمة التي تظهر كثيرًا في مستند واحد ومرة قليلة في باقي المستندات = مهمة

الكلمة الشائعة جدًا مثل "في، من، على" = أقل أهمية

ما هي Word Embeddings؟

هي طريقة لتمثيل الكلمات كـ متجهات رقمية dense vectors بحيث تعكس المعنى والعلاقة بين الكلمات.

مثال:

"ملك" و"أمير" يكونان قريبين

"تفاحة" و"حاسوب" بعيدين

فائدتها:

تجعل النموذج يفهم العلاقات الدلالية

أفضل من BoW و TF-IDF في فهم المعنى

ما الفرق بين Word2Vec و GloVe؟

Word2Vec

يتعلم من السياق المحلي

يعتمد على الشبكات العصبية

نوعان:

CBOW

Skip-gram

GloVe

يتعلم من الإحصاءات العالمية للكلمات

يعتمد على مصفوفة التشارك بين الكلمات

الفرق:

Word2Vec: يركز على الكلمات المجاورة

GloVe: يركز على العلاقات العامة في كامل البيانات

ما هي التحديات في اللغة العربية؟

اللغة العربية من أصعب اللغات في NLP بسبب:

التشكيل

عَلَم / عِلْم

الاشتقاق الصرفي

كتب، يكتب، مكتوب، كتابة

اللهجات

العربية الفصحى ≠ العامية

التصاق الأدوات

"وبالمدرسة"

قلة البيانات المعلّمة مقارنة بالإنجليزية

اختلاف الكتابة

"إلى" / "الى"

"أ" / "ا"

اشرح مفهوم .Language Modeling

Language Model هو نموذج يتعلم أنماط اللغة ويهدف إلى توقع الكلمة التالية أو المفقودة.

مثال:

"أنا أدرس الذكاء _____" النموذج قد يتوقع: الاصطناعي

الاستخدامات:

الترجمة

التلخيص

المحادثة

التصحيح التلقائي

توليد النصوص

مهم جدًا في Transformer

ما هو Attention Mechanism؟

Attention هي آلية تجعل النموذج يركز على الكلمات الأكثر أهمية أثناء الفهم أو التوليد.

مثال:

في الجملة: "الولد رمى الكرة لأنه كان غاضبًا"

عند فهم "كان"، يجب على النموذج الانتباه إلى الولد وليس الكرة.

فائدته:

تحسين فهم العلاقات البعيدة

ما الفرق بين RNN و Transformer؟

يعالج النص تسلسليًا كلمة كلمة

بطيء

يواجه مشكلة نسيان المعلومات البعيدة

Transformer

يعالج الكلمات بالتوازي

أسرع

يستخدم Self-Attention

يفهم العلاقات البعيدة بشكل أفضل

النتيجة:

Transformer أفضل غالبًا من RNN

ما هو NER مع مثال؟

NER = Named Entity Recognition

هو التعرف على الكيانات المهمة داخل النص.

أنواع الكيانات:

شخص

مكان

منظمة

تاريخ

مثال:

"زار محمد مدينة صنعاء يوم الجمعة"

النتيجة:

محمد → Person

صنعاء → Location

الجمعة → Date

اشرح .POS Tagging

POS Tagging = تعيين النوع النحوي لكل كلمة.

مثال:

"محمد يدرس الذكاء"

محمد ← اسم

يدرس ← فعل

الذكاء ← اسم

الفائدة:

فهم الجملة نحويًا

مفيد في:

الترجمة

التحليل النحوي

استخراج المعلومات

ما هو Sentiment Analysis؟

هو تحليل المشاعر لمعرفة هل النص:

إيجابي

سلبي

محايد

مثال:

"هذا الفيلم رائع جدًا" ← Positive

"الخدمة سيئة جدًا" ← Negative

الاستخدامات:

تحليل آراء العملاء

تقييم المنتجات

مراقبة السوشيال ميديا

ما هو Overfitting وكيف تعالجه؟

Overfitting يحدث عندما يتعلم النموذج بيانات التدريب أكثر من اللازم حتى يفشل في التعميم على بيانات جديدة.

علاماته:

دقة عالية جدًا على التدريب

دقة منخفضة على الاختبار

الحلول:

زيادة البيانات

تقليل تعقيد النموذج

Regularization

Dropout

Cross Validation

Early Stopping

ما الفرق بين Supervised و Unsupervised في NLP؟

Supervised Learning

البيانات فيها Labels

مثال:

تصنيف المشاعر

تصنيف الرسائل

Unsupervised Learning

البيانات بدون Labels

مثال:

Clustering

Topic Modeling

الفرق:

Supervised: نتعلم من إجابات صحيحة

Unsupervised: نبحث عن أنماط مخفية

القسم الثالث: أسئلة عملية وتحليلية (١٥ سؤال)

قم بعمل Tokenization للجملة:

"الذكاء الاصطناعي يغير العالم"

"]الذكاء"، "الاصطناعي"، "يغير"، "العالم"]

احذف Stop Words من الجملة:

"أنا أريد أن أتعلم معالجة اللغات الطبيعية"

"]أريد"، "أتعلم"، "معالجة"، "اللغات"، "الطبيعية"]

إذا ظهرت كلمة في ٥٠ مستند من أصل ١٠٠٠:

احسب IDF تقريبياً

احسب Cosine Similarity بين

متجهين بسيطين (أعطِ مثال).

لديك بيانات نصية:

كيف تحوّلها إلى أرقام؟

يمكن تحويل النصوص إلى أرقام باستخدام:

Bag of Words

TF-IDF

Word2Vec

GloVe

BERT Embeddings

الأفضل حسب الحالة:

مشروع بسيط → TF-IDF

مشروع متقدم → BERT embeddings

صمّم Pipeline لمعالجة النصوص.

NLP Pipeline

جمع البيانات

تنظيف النص

إزالة الرموز

إزالة الروابط

توحيد الحروف

Tokenization

Stop Words Removal

Stemming / Lemmatization

Feature Extraction

TF-IDF / Embeddings

Training

Evaluation

Prediction / Deployment

لديك Dataset صغير:

أي نموذج تختار ولماذا؟

الأفضل:

Naive Bayes أو Logistic Regression

لماذا؟

سريعة

تعمل جيدًا مع النصوص

لا تحتاج بيانات ضخمة

مناسبة مع TF-IDF

لديك Dataset كبير:

ما النموذج الأفضل؟

الأفضل:

Transformer-based models مثل:

BERT

AraBERT للعربية

GPT لبعض المهام التوليدية

لماذا؟

تفهم السياق

تعطي دقة أعلى

تستفيد من البيانات الكبيرة

كيف تحسن دقة نموذج تصنيف نصوص؟

تنظيف البيانات جيدًا

استخدام TF-IDF بدل Count فقط

استخدام Embeddings

اختيار نموذج أفضل

ضبط Hyperparameters

زيادة البيانات

موازنة الفئات

استخدام Fine-tuning لنموذج جاهز

كيف تتعامل مع النصوص العربية؟

توحيد الحروف

أ / إ / آ ← ا

ة ← ه أو تبقى حسب النظام

إزالة التشكيل

إزالة التكرار

جمييييل ← جميل

Tokenization عربية مناسبة

استخدام Arabic stop words

استخدام Stemming / Lemmatization

الأفضل استخدام نموذج عربي مثل:

AraBERT

صمّم نظام .Sentiment Analysis

تصنيف النص إلى:

Positive

Negative

Neutral

الخطوات:

جمع بيانات تقييمات

تنظيف النص

Tokenization

إزالة Stop Words

تحويل النص إلى TF-IDF أو Embeddings

تدريب نموذج:

Naive Bayes / Logistic Regression / BERT

تقييم الأداء:

Accuracy

Precision

Recall

F1-score

لديك مشكلة :Overfitting

اقترح ٣ حلول

الحلول:

زيادة البيانات

تقليل تعقيد النموذج

استخدام Regularization أو Dropout

ويمكن أيضًا:

Early Stopping

Cross Validation

قارن بين:

Naive Bayes

Logistic Regression

Naive Bayes

المميزات:

سريع جدًا

ممتاز للـ text classification

جيد مع البيانات الصغيرة

العيوب:

يفترض استقلالية الكلمات (وهذا غير واقعي دائمًا)

Logistic Regression

المميزات:

غالبًا أدق من Naive Bayes

سهل الفهم

ممتاز مع TF-IDF

العيوب:

أبطأ قليلًا من Naive Bayes

الخلاصة:

سرعة وبساطة → Naive Bayes

دقة أفضل غالبًا → Logistic Regression

لديك نصوص غير نظيفة:

كيف تنظفها؟

إزالة الرموز الخاصة

إزالة الروابط

إزالة الإيموجي (إذا غير مهمة)

إزالة الأرقام (حسب المهمة)

تحويل النص لصيغة موحدة

إزالة التشكيل

توحيد الحروف

حذف Stop Words

تصحيح التكرار

صمّم مشروع NLP كامل (من البداية للنهاية)

مثال مشروع:

تصنيف تعليقات الطلاب إلى إيجابي / سلبي

الخطوات:

تحديد المشكلة

جمع البيانات

تنظيف البيانات

استكشاف البيانات

Tokenization

Feature Extraction

TF-IDF أو BERT

تقسيم البيانات:

Train / Validation / Test

تدريب النموذج

تقييم النموذج

تحسين الأداء

نشر النموذج ((Deployment

بناء واجهة استخدام

ما هو Byte Pair Encoding (BPE)؟

أ) خوارزمية ضغط نصوص

ب) طريقة Tokenization

ج) نموذج لغة

د) خوارزمية تصنيف

Subword Tokenization تستخدم لـ:

أ) حذف الكلمات

ب) التعامل مع الكلمات النادرة

ج) ترجمة النص

د) ضغط البيانات

ما هو n-gram؟

أ) نموذج عميق

ب) تسلسل من n كلمات

ج) خوارزمية

د) قاعدة بيانات

Bigram يعني:

أ) كلمة واحدة

ب) كلمتين

ج) ثلاث كلمات

د) أربع كلمات

Trigram يعني:

أ) كلمتين

ب) ثلاث كلمات

ج) أربع كلمات

د) خمس كلمات

Perplexity تستخدم لـ:

أ) قياس جودة النموذج اللغوي

ب) ضغط النص

ج) حذف الكلمات

د) تصنيف الصور

BLEU Score يستخدم في:

أ) تصنيف النص

ب) الترجمة الآلية

ج) تحليل المشاعر

د) clustering

ROUGE يستخدم في:

أ) الترجمة

ب) التلخيص

ج) التصنيف

د) التعلم العميق

Seq2Seq Model يستخدم في:

أ) التصنيف

ب) الترجمة

ج) clustering

د) PCA

Encoder يقوم بـ:

أ) توليد النص

ب) تمثيل الإدخال

ج) حذف الكلمات

د) ضغط الصور

Decoder يقوم بـ:

أ) تحليل الصور

ب) توليد النص

ج) حذف الكلمات

د) تصنيف البيانات

Masked Language Model:

أ) يتوقع الكلمة المحذوفة

ب) يترجم النص

ج) يصنف النص

د) يضغط البيانات

Autoregressive Model:

أ) يتوقع كل الكلمات دفعة واحدة

ب) يتوقع الكلمة التالية

ج) لا يستخدم سياق

د) نموذج ثابت

Transformer يتكون من:

أ) Encoder فقط

ب) Decoder فقط

ج) Encoder و Decoder

د) CNN

Self-Attention:

أ) يعتمد على الصور

ب) يربط الكلمات ببعضها

ج) يحذف الكلمات

د) يضغط النص

Positional Encoding يستخدم لـ:

أ) حذف الترتيب

ب) تمثيل ترتيب الكلمات

ج) ضغط النص

د) حذف الكلمات

Fine-tuning يعني:

أ) تدريب من الصفر

ب) تحسين نموذج جاهز

ج) حذف البيانات

د) ضغط النموذج

Transfer Learning:

أ) تدريب جديد

ب) نقل المعرفة

ج) حذف البيانات

د) تصنيف الصور

Zero-shot Learning:

أ) تدريب كامل

ب) بدون تدريب مباشر

ج) تعلم عميق

د) clustering

Few-shot Learning:

أ) بيانات كثيرة

ب) بيانات قليلة

ج) بدون بيانات

د) ضغط البيانات

✍القسم الخامس: أسئلة نظرية متقدمة (١٥ سؤال)

اشرح Subword Tokenization ولماذا هي مهمة.

هي تقسيم الكلمة إلى أجزاء أصغر من الكلمة بدل اعتبار الكلمة كاملة وحدة واحدة.

مثال:

كلمة: unhappiness

قد تُقسَّم إلى:

un

happy

ness

لماذا مهمة؟

التعامل مع الكلمات النادرة

تقليل مشكلة Out-of-Vocabulary

مناسبة جدًا للغات ذات الاشتقاق مثل العربية

أمثلة عليها:

BPE

WordPiece

SentencePiece

ما الفرق بين:

Autoregressive Models

Masked Language Models

Autoregressive Models

تتنبأ بالكلمة التالية

تقرأ النص من اليسار إلى اليمين غالبًا

مثال: GPT

مثال:

"أنا أحب الذكاء _____" → يتوقع الكلمة التالية

Masked Language Models

تخفي كلمة داخل الجملة وتحاول توقعها

مثال: BERT

مثال:

"أنا أحب [MASK]الاصطناعي" → يتوقع "الذكاء"

الفرق:

GPT: توليد نص

BERT: فهم سياق النص

اشرح مفهوم Perplexity وكيف يتم استخدامه.

Perplexity هو مقياس لمدى جودة النموذج اللغوي في توقع الكلمات.

الفكرة:

إذا كان النموذج واثقًا في توقعه ← Perplexity أقل

إذا كان مرتبكًا ← Perplexity أعلى

القاعدة:

كلما كانت Perplexity أقل، كان النموذج أفضل

الاستخدام:

تقييم Language Models

مقارنة النماذج اللغوية

ما الفرق بين BLEU و ROUGE بالتفصيل؟

يستخدم غالبًا في الترجمة الآلية

يقارن النص الناتج بالنص المرجعي بناءً على n-grams

يركز على:

Precision

أي: كم من الكلمات/العبارات الناتجة كانت صحيحة

ROUGE

يستخدم غالبًا في التلخيص يقارن الناتج بالمرجع ويركز أكثر على Recall

يركز على:

Recall

أي: كم من المعلومات المرجعية تم التقاطها

الفرق:

BLEU → ترجمة

ROUGE → تلخيص

اشرح بنية Transformer بالتفصيل.

الـ Transformer هو معمارية حديثة في NLP تعتمد على Attention بدل RNN.

يتكون من:

1. Encoder

يمثل النص المدخل

2. Decoder

يولد النص الناتج

كل Encoder Layer يحتوي على:

Self-Attention

Feed Forward Network

Add & Norm

كل Decoder Layer يحتوي على:

Masked Self-Attention

Encoder-Decoder Attention

Feed Forward

Add & Norm

مميزاته:

سريع

يفهم السياق

يدعم التدريب المتوازي

ما هو Self-Attention وكيف يعمل؟

هو آلية تسمح لكل كلمة أن تنظر إلى الكلمات الأخرى في الجملة لتفهم معناها بدقة.

مثال:

في الجملة: "الطالب قرأ الكتاب لأنه مفيد"

كلمة "مفيد" يجب أن ترتبط غالبًا بـ "الكتاب"

كيف يعمل؟

كل كلمة تنتج:

Query

Key

Value

ثم يتم حساب مدى أهمية كل كلمة بالنسبة للأخرى.

الفائدة:

فهم العلاقات بين الكلمات

فهم السياق البعيد

ما هي Positional Encoding ولماذا نحتاجها؟

لأن Transformer لا يقرأ النص تسلسليًا مثل RNN، فهو يحتاج طريقة لتمثيل ترتيب الكلمات.

مثال:

"أكل أحمد التفاحة"

"أكلت التفاحة أحمد"

نفس الكلمات لكن المعنى مختلف بسبب الترتيب.

الحل:

إضافة Positional Encoding لكل كلمة حتى يعرف النموذج موقعها.

اشرح الفرق بين Encoder و Decoder في .Transformer

يأخذ النص المدخل

يحوله إلى تمثيل غني بالمعلومات

Decoder

يأخذ هذا التمثيل

يولد النص الناتج كلمة بكلمة

مثال في الترجمة:

Encoder: يفهم الجملة العربية

Decoder: يولد الجملة الإنجليزية

ما هو Fine-tuning ولماذا هو مهم؟

Fine-tuning يعني أخذ نموذج مدرب مسبقًا مثل BERT أو AraBERT ثم إعادة تدريبه على مهمة محددة.

مثال:

نموذج عام للغة

نعدله ليصنف المشاعر

لماذا مهم؟

أسرع من التدريب من الصفر

يحتاج بيانات أقل

يعطي أداء أعلى

ما هو Transfer Learning في NLP؟

هو نقل المعرفة من نموذج تعلم مسبقًا على بيانات كبيرة إلى مهمة جديدة.

مثال:

نموذج تعلم اللغة من ملايين النصوص

نستخدمه في:

تصنيف النص

NER

الترجمة

فائدته:

تقليل الوقت

تقليل البيانات المطلوبة

تحسين الأداء

ما هو Zero-shot Learning مع مثال؟

هو أن ينجز النموذج مهمة بدون أن يتدرب عليها مباشرة.

مثال:

تسألين النموذج:

"صنّف هذا النص إلى إيجابي أو سلبي"

حتى لو لم يتم تدريبه تحديدًا على بياناتك.

الفرق:

Zero-shot: بدون أمثلة

Few-shot: مع أمثلة قليلة

ما الفرق بين GPT و BERT؟

Autoregressive

يتنبأ بالكلمة التالية

ممتاز في:

توليد النص

المحادثة

الكتابة

BERT

Masked Language Model

يفهم الكلمة من السياق الكامل

ممتاز في:

الفهم

التصنيف

NER

QA

الخلاصة:

GPT = توليد

BERT = فهم

اشرح Seq2Seq Model مع مثال.

هو نموذج يحول تسلسل إلى تسلسل.

مثال:

ترجمة:

Input: "أنا أحب البرمجة"

Output: "I love programming"

يتكون من:

Encoder

Decoder

الاستخدامات:

الترجمة

التلخيص

المحادثة

ما هي التحديات في بناء Chatbot؟

فهم نية المستخدم

فهم السياق السابق

التعامل مع الغموض

دعم اللهجات

تقديم إجابات دقيقة

التعامل مع الأخطاء الإملائية

إدارة الحوار طويل المدى

الأمان ومنع الردود الضارة

كيف تقيم نموذج NLP؟ ((metrics

حسب المهمة:

Classification

Accuracy

Precision

Recall

F1-score

Language Model

Perplexity

Translation

BLEU

Summarization

ROUGE

NER / Sequence Labeling

Precision / Recall / F1

القسم السادس: أسئلة عملية / تصميم أنظمة (١٥ سؤال)

لديك نص طويل:

كيف تقوم بتلخيصه باستخدام NLP؟

الخطوات:

تنظيف النص

تقسيمه إلى جمل

استخدام نموذج تلخيص:

Extractive

Abstractive

تقييم الناتج بـ ROUGE

النماذج:

T5

BART

PEGASUS

صمّم نظام ترجمة آلية بسيط.

جمع جمل مترجمة

تنظيف النص

Tokenization

استخدام Seq2Seq أو Transformer

تدريب النموذج

تقييمه بـ BLEU

نشر النظام

لديك بيانات متعددة اللغات:

كيف تتعامل معها؟

تحديد اللغة أولًا

توحيد التنسيق

استخدام نماذج متعددة اللغات مثل:

mBERT

XLM-R

أو تدريب نموذج لكل لغة

كيف تبني Chatbot ذكي؟

Intent Detection

Entity Extraction

Dialogue Management

Response Generation

Memory / Context

يمكن بناؤه باستخدام:

قواعد بسيطة

أو LLM / Transformer

لديك مشكلة Ambiguity في النص:

كيف تعالجها؟

الحل:

استخدام السياق

استخدام Transformer

Word Sense Disambiguation

الاستفادة من الجملة كاملة بدل الكلمة وحدها

مثال:

"عين" قد تعني:

عضو في الجسم

نبع ماء

جاسوس

كيف تتعامل مع Out-of-Vocabulary words؟

الحلول:

Subword Tokenization

Character-level models

استخدام BPE / WordPiece

تحديث القاموس إذا لزم

لديك Dataset غير متوازن:

كيف تعالجه؟

لديك Dataset غير متوازن: كيف تعالجه؟

الحلول:

Oversampling

Undersampling

Class weights

استخدام F1-score بدل Accuracy فقط

جمع بيانات إضافية للفئة الأقل

كيف تبني نظام NER باستخدام Deep Learning؟

الخطوات:

جمع بيانات موسومة

Tokenization

تمثيل الكلمات بـ Embeddings

استخدام نموذج:

BiLSTM + CRF

أو BERT

تدريب النموذج

تقييمه بـ Precision / Recall / F1

كيف تستخدم Transformer في مشروعك؟

في مشروع تصنيف مشاعر:

استخدم BERT / AraBERT

مرر النص إلى النموذج

Fine-tuning على بياناتك

التنبؤ بالفئة

كيف تختار بين:

BERT

GPT

اختاري BERT إذا كانت المهمة:

Classification

NER

QA

فهم النص

اختار GPT إذا كانت المهمة:

توليد نص

Chatbot

كتابة / تلخيص / إكمال

قاعدة سهلة للحفظ:

BERT = Understand

GPT = Generate

حسب المهمة؟

لديك نصوص :noisy

كيف تنظفها؟ ((advanced level

إزالة HTML

إزالة الروابط

إزالة mentions / hashtags حسب المهمة

تصحيح التكرار

توحيد الترميز

إزالة التشكيل

إزالة الرموز الغريبة

تصحيح الأخطاء الإملائية (اختياري)

التعامل مع الإيموجي حسب المهمة

كيف تحسن سرعة inference لنموذج NLP؟

استخدام نموذج أصغر

Quantization

Distillation

تقليل طول الإدخال

Batch inference

استخدام GPU/TPU

صمّم نظام .Question Answering

الخطوات:

استقبال السؤال

جلب المستندات ذات الصلة

تمرير السؤال + النص إلى نموذج QA

استخراج الإجابة

النماذج:

BERT QA

Retrieval + Reader

كيف تبني نظام Text Summarization؟

نوعان:

Extractive

اختيار أهم الجمل

Abstractive

توليد ملخص جديد

الخطوات:

تنظيف النص

تقطيعه

استخدام نموذج:

BART

T5

تقييمه بـ ROUGE

صمّم نظام NLP متكامل لشركة (مثلاً بنك أو خدمة عملاء)

مثال: نظام خدمة عملاء ذكي

الوظائف:

تصنيف طلب العميل

استخراج البيانات المهمة (اسم، رقم طلب)

الرد الآلي

تحليل مشاعر العميل

تلخيص المحادثات

تحويل الحالات الصعبة للموظف

التقنيات:

Intent Classification

NER

Sentiment Analysis

Chatbot

Summarization